



UNIVERSIDAD
DE BURGOS

Curso: 2025-2026

NUEVAS TECNOLOGÍAS Y EMPRESA

Project Link Prediction Kaggle Competición

Descripción breve

Desarrollo de la práctica final de Kaggle del equipo LosTrifuerza de la asignatura Nuevas Tecnologías y Empresa de 4º de Ingeniería Informática de la Universidad de Burgos impartida por José Ignacio Santos Martín

Rubén Castañeda Matute y Roberto Iturralde Zarzo

INDICE

0.PREPASOS	2
1.INTRODUCCIÓN	2
2.ENFOQUE DEL PROBLEMA	2
3.INGENIERÍA DE CARACTERÍSTICAS (FEATURE ENGINEERING)	2
4.MODELO DE APRENDIZAJE AUTOMÁTICO	3
5.TABLA DE FASES DEL PROYECTO	3
6.CONCLUSIÓN	3

0. PREPASOS

Antes de iniciar la practica es necesario tener instaladas varias librerías, se pueden instalar desde la carpeta base del proyecto con el comando “pip install -r requirements.txt”

1. INTRODUCCIÓN

Este proyecto aborda el reto de identificar enlaces ocultos en una red social universitaria basada en interacciones de correo electrónico. Utilizando técnicas de Ciencia de Redes y Aprendizaje Automático, el equipo LosTrifuerza ha desarrollado un modelo capaz de distinguir entre pares de nodos con alta probabilidad de conexión y aquellos que no están vinculados.

2. ENFOQUE DEL PROBLEMA

Siguiendo las metodologías impartidas en la asignatura, hemos transformado el grafo en un dataset de entrenamiento supervisado. En lugar de predecir basándonos solo en la topología visual, hemos extraído "pistas" numéricas (Características estructurales) que definen la cercanía entre dos individuos en la red.

3. INGENIERÍA DE CARACTERÍSTICAS (FEATURE ENGINEERING)

Para cada par de nodos (u, v), hemos calculado métricas de proximidad local:

- ➔ **Coefficiente de Jaccard:** Mide la proporción de vecinos compartidos respecto al total de vecinos de ambos nodos.
- ➔ **Índice Adamic-Adar:** Pondera los vecinos comunes inversamente al logaritmo de su grado, priorizando conexiones a través de "puentes" exclusivos.
- ➔ **Preferential Attachment:** Basado en la teoría de que nodos con alto grado tienden a conectarse entre sí.
- ➔ **Resource Allocation Index:** Similar a Adamic-Adar, mide la transferencia de recursos a través de nodos intermedios.

4.MODELO DE APRENDIZAJE AUTOMÁTICO

Se ha implementado un clasificador Random Forest (Bosque Aleatorio). Este modelo es ideal para la predicción de enlaces porque:

- ➔ Maneja relaciones complejas y no lineales entre las métricas.
- ➔ Es robusto frente al ruido de los datos de redes sociales reales.
- ➔ Permite evaluar la importancia de cada característica en la predicción final.

5.TABLA DE FASES DEL PROYECTO

Fase	Acción Realizada
Preprocesamiento	Carga del archivo GEXF y normalización de etiquetas de nodos.
Muestreo Negativo	Generación de ejemplos "falsos" (nodos no conectados) para equilibrar el entrenamiento.
Entrenamiento	Ajuste del Random Forest con validación cruzada (K-fold).
Predicción Final	Aplicación del modelo sobre el conjunto de test para Kaggle.

6.CONCLUSIÓN

La combinación de métricas estructurales clásicas con un modelo de ensamble supervisado permite recuperar los enlaces eliminados con una precisión superior a los métodos puramente heurísticos. El resultado final se presenta en el archivo submission.csv siguiendo estrictamente el formato solicitado.